

Projet Partie 2 : Segmentation et Scoring

Cas Assurance Mobil-Home

Table des matières

Contexte et besoin métier	1
Comprendre et préparer le jeu de donnée	1
Analyse factorielle des correspondances multiples	2
Segmentation des clients	2
Choix du nombre de groupes	2
Description des groupes	3
Modélisation prédictive : régression logistique	3
Méthodologie	3
Validation et performances	4
Généralisation et ciblage des prospects	4
Conclusion	4
Annexes	4

Contexte et besoin métier

Notre jeux de données comprend 5 822 clients. Seule une minorité d'entre eux (environ 6 %) est couverte par l'assurance Mobil-Home. Le projet a deux objectifs :

- Segmentation : comprendre la structure de la base clients en identifiant des groupes homogènes .
- Scoring : élaborer un modèle prédictif évaluant la probabilité qu'un client souscrive à l'assurance Mobil-Home afin de cibler les prospects les plus pertinents.

La démarche est autour d'une préparation des données, d'une analyse factorielle pour explorer les liaisons entre variables qualitatives, d'un clustering pour construire la classification de clients, puis d'une régression logistique pour prédire l'attrance au produit.

Comprendre et préparer le jeu de donnée

La qualité du modèle dépend de la fiabilité des données. Le jeu de données mis à disposition présentait quelques incohérence , nous avons du intervenir sur Excel pour nettoyer ces données (valeur manquantes ,fusionner des variables à l'aide du filtrage) , effectuer des tableaux croisés dynamique pour pour analyser les données .

Les valeurs manquantes ont été ajoutées, les modalités trop rares ont été regroupées pour limiter leur influence.

Voici des exemples de variables que nous avons modifiées :

- Discrétisation et recodage : les variables numériques ont été transformées en classes socio-démographiques afin de faciliter l'analyse :
- Taille du foyer (avgsiz) : catégories 1 personne, 2 personnes, 3 personnes, 4 et plus.
- Âge moyen (avgage) : tranches 20-30 ans, 30-40 ans, 40-50 ans, 50-60 ans et 60 ans et plus.
- Revenus moyens (avgincom) : classes < 45 000 €, 45-75 000 €, > 75 000 €.
- Variables de contrat : les indicateurs binaires Car_policie, Third_party_insur, Moto_policie, Life_insur, Accident_insur et Mobil_home_policie sont recodés sous forme de modalités « 0 / 1 »

Cette transformation produit un tableau final de 5 822 lignes et 10 colonnes (avgsiz, avgage, cust, avgincom, Car, Third, Moto, Life, Accident, Mobilhome) prêt pour l'analyse.

Analyse factorielle des correspondances multiples

L'AFCM permet d'explorer les relations entre les variables qualitatives et de réduire la dimension du problème. Les deux premiers axes expliquent environ 19,4 % de l'inertie totale. Sur le plan factoriel on observe :

- Axe 1 : niveau de vie et structure familiale : il oppose les familles aisées et nombreuses (classements Avg_size_4 et plus, Avg_incom > 75 000 €) aux personnes seules à faibles revenus (Avg_size_1, Avg_incom < 45 000 €).
- Axe 2 : cycle de vie : il distingue les seniors stables et multi-assurés (assurances auto, vie, accident) des jeunes ou célibataires peu équipés.

La variable cible Mobilhome se projette dans le quadrant « revenus élevés / couples mûrs », affirmant que le produit est davantage souscrit par des familles aisées et installées.

La projection des variables principales montre l'influence de chaque variable.

Segmentation des clients

Choix du nombre de groupes

Les résultats de l'AFCM sont soumis à un clustering par **K-means** pour différents nombres de groupes. L'évolution du R^2 cumulé en fonction du nombre de clusters montre un coude autour de 5 groupes (graphique en annexe), au-delà le gain de qualité devient marginal.

Une Classification ascendante hiérarchique (méthode de Ward) confirme l'existence de cinq segments. (voir graphique en annexe)

Description des groupes

L'analyse distingue cinq groupes de clients, chacun présentant des caractéristiques et un intérêt spécifique pour l'offre Mobil-Home.

Le premier groupe, constitué de jeunes familles actives, représente un potentiel futur intéressant : bien qu'elles ne soient pas encore la cible principale, leur évolution démographique et financière en fait une réserve de croissance à moyen terme.

Le deuxième groupe, composé de couples seniors modestes, affiche un faible potentiel en raison de contraintes budgétaires qui limitent leur capacité à souscrire ce type d'assurance.

Le troisième groupe réunit des familles aisées (âgées de 40 à 50 ans, avec des revenus supérieurs à 75 000 € et des foyers de quatre personnes ou plus) : il s'agit de la cible cœur, la majorité des souscripteurs actuels et présentant donc le plus fort intérêt pour le développement commercial.

Le quatrième groupe, constitué de personnes isolées à faibles revenus, présente un potentiel nul pour le produit Mobil-Home, étant donné leur pouvoir d'achat limité et leur faible propension à s'équiper.

Enfin, le cinquième groupe regroupe des profils atypiques, représentant une niche : bien que leur effectif soit réduit, ils peuvent offrir des opportunités spécifiques grâce à leurs besoins particuliers. Ainsi, la segmentation (graphique en annexe) permet de cibler prioritairement les familles aisées tout en identifiant les autres groupes à potentiel différencié pour adapter la stratégie marketing.

Modélisation prédictive : régression logistique

Méthodologie

Le fichier recodé est déséquilibré, en effet 348 clients ayant l'assurance contre 5 474 non-assurés. Pour éviter un modèle biaisé, nous avons constitué un échantillon équilibré (348 « oui » et 348 « non ») puis l'avons scindé en 80 % apprentissage et 20 % test.

La variable réponse est Mobilhome, les prédicteurs sont avgsiz, avgage, avgincom, Car, Third, Moto, Life et Accident.

La régression logistique fournit des coefficients qui peuvent être interprétés :

- Car 1 (possède un contrat auto) : coefficient +1,36 .
La possession d'une assurance automobile est le facteur le plus discriminant en faveur de la souscription Mobil-Home.
- avgincom < 45 k€ : coefficient -0,56.
Les revenus modestes réduisent fortement la probabilité d'adhésion.
- avgsiz « 4 et plus » : coefficient +1,02.
Les familles nombreuses sont plus enclines à assurer un Mobil-Home.

Les autres variables, telles la détention d'un contrat Moto, Life ou Accident, ainsi que la souscription à une assurance Tiers (Third), n'ont pas de significativité statistique marquée (p -value > 5 %).

Une p -value supérieure à 5 % signifie qu'il n'existe pas de preuve suffisante pour rejeter l'hypothèse nulle concernant l'influence de ces variables sur la souscription à une assurance Mobil-Home, autrement dit, leur effet n'est pas considéré comme statistiquement significatif dans ce modèle.

Validation et performances

Sur l'échantillon de test (138 individus), la matrice de confusion affiche une précision globale de 68,84 % . (Le tableau en annexe résume les prédictions) .

Le modèle identifie correctement 51 acheteurs sur 69 (74 %) et 44 non-acheteurs sur 69. Avec un taux de bonne classification proche de 70 %, il se révèle suffisamment fiable pour une utilisation marketing. Les coefficients permettent de dériver des règles simples en effet « Si le client possède un contrat auto ET appartient à une famille nombreuse ALORS la probabilité de souscription est élevée ».

Généralisation et ciblage des prospects

En triant les scores décroissants, nous obtenons un classement des prospects. Pour des raisons opérationnelles, nous avons extrait les 50 clients présentant la probabilité la plus élevée. Ces prospects sont nos meilleurs clients (familles aisées, motorisées). Ils constituent la cible d'une campagne marketing personnalisée.

Conclusion


L'étude montre que l'assurance Mobil-Home attire principalement des familles aisées, motorisées et déjà assurées. Les analyses mettent en valeur trois enseignements majeurs :

1. Segmentation claire : une classification en 5 groupes distingue nettement les familles aisées des profils précaires.
2. Facteurs clés : la possession d'une assurance auto, la taille du foyer et le niveau de revenu sont les variables déterminantes pour la souscription Mobil-Home.
3. Modèle robuste : le score logistique fournit une précision d'environ 69 %, suffisante pour piloter une action commerciale ciblée.

Annexes

Analyse factorielle des correspondances multiples (AFCM) :

Projection des variables et individus sur les deux premiers axes




Code R :

```
#2 AFM
# On affiche les noms pour trouver où est "Cust_Typ"
names(donnees)
# 1. CHARGER LA LIBRAIRIE
library(FactoMineR)
# 2. LANCER L'AFM
# quali.sup = 3 : On dit à R que la 3ème colonne ("cust") ne participe pas à la
# construction des axes
# graph = TRUE : Affiche le nuage de points
res.mca <- MCA(donnees, quali.sup = 3, graph = TRUE)

# 3. AFFICHER LES RÉSULTATS POUR LE TABLEAU
# Cela affiche les variables les plus liées à l'Axe 1 et l'Axe 2
```

```
dimdesc(res.mca, axes = 1:2)
```

Méthode K-Means et Coude :



Qualité de la segmentation en fonction du nombre de groupes

Code R :

```
# 3 KMEANS
```

```
# 1. On récupère les coordonnées des clients calculées  
donnees_clients <- res.mca$ind$coord
```

```
# 2. On teste de 2 à 10 groupes pour trouver le meilleur découpage  
# On crée un tableau vide pour noter les scores  
R2 <- data.frame(Nb_Groupes = 2:10, R_Carre = NA)
```


```
# On lance la boucle  
for (k in 2:10) {  
  # On calcule le K-Means pour k groupes  
  # nstart=25 assure que le résultat est stable et fiable  
  modele <- kmeans(donnees_clients, centers = k, nstart = 25)
```

```
  # On calcule le  $R^2$  = Inter-classe / Totale  
  r_carre <- modele$betweenss / modele$totss
```

```
  # On stocke le résultat dans le tableau  
  R2$R_Carre[R2$Nb_Groupes == k] <- round(r_carre, 4)  
}
```

```
# 4. AFFICHER LE GRAPHIQUE (Pour repérer le "coude")  
plot(R2$Nb_Groupes, R2$R_Carre, type="b", pch=19, col="blue",  
      main="Qualité de la segmentation ( $R^2$ )",  
      xlab="Nombre de groupes", ylab=" $R^2$ ")  
grid()
```

Dendrogramme :



Dendrogramme de la CAH


Code R :

```
library(cluster)
# method="ward" permet de créer des groupes compacts et homogènes
cah <- agnes(res.mca$ind$coord, diss=FALSE, metric = "euclidean", stand=FALSE,
method = "ward")
# Affichage du Dendrogramme
pltree(cah, cex = 0.6, hang = -1, main = "Dendrogramme (CAH - Ward)")
# On coupe l'arbre pour obtenir 5 familles de clients
groupes_cah <- cutree(cah, k = 5)
print(table(groupes_cah))
```

Description des groupes :

Groupe 1	1 227	Jeunes familles actives	Potentiel futur
Groupe 2	1 909	Couples seniors modestes	Faible (budget faible)
Groupe 3	1 916	Familles aisées (40-50 ans, revenus > 75 k€, foyers ≥ 4 personnes)	Cible Cœur

Groupe 4	463	Isolés (revenus faibles)	Nul
Groupe 5	307	Profils atypiques	Niche



Catégories et groupes projetés sur le plan factoriel

Code R :

```
# Visualisation avancée des groupes
don_afcm2 <- donnees
don_afcm2$grp <- donnees$km

# On relance une ACM spécifique pour projeter les groupes dessus
afcm2 <- MCA(don_afcm2, quali.sup = ncol(don_afcm2), graph = FALSE)

fviz_mca_var(afcm2, repel = TRUE)
# Affiche les individus colorés selon leur groupe d'appartenance
fviz_mca_ind(afcm2, label = "none", habillage = donnees$grp,
  addEllipses = TRUE)
```

Modélisation prédictive : régression logistique

Code R :

```
# Équilibrage des données
```

```
# On prend tous les clients "Oui" et on tire au hasard autant de "Non"
don_ech <- donnees %>%
  group_by(Mobilhome) %>%
  slice_sample(n = min(table(donnees$Mobilhome))) %>%
  ungroup()
print(table(don_ech$Mobilhome))

# Découpage Apprentissage / Test
# 80% pour apprendre, 20% pour vérifier
echantillon <- createDataPartition(don_ech$Mobilhome, p = 0.8, list = FALSE)
train <- don_ech[echantillon, ]
test <- don_ech[-echantillon, ]
# Modélisation (Régression Logistique)
# On cherche à expliquer Mobilhome par les variables socio-démographiques
formule <- Mobilhome ~ avgsiz + avgage + avgincom + Car + Third + Moto + Life + Accident
modele <- glm(formule, family = binomial(link = "logit"), data = train)
# Affiche les résultats
summary(modele)
```

Validation et performances :

	Réel : NON (69)	Réel : OUI (69)	Total
Prédit : NON	44 (vrais négatifs)	18 (ratés)	62
Prédit : OUI	25 (faux positifs)	51 (vrais positifs)	76
Total	69	69	138

Code R :

```
# 1. On calcule les probabilités pour les clients du fichier TEST

test$prob <- predict(modele, newdata = test, type = "response")

# 2. On transforme la probabilité en décision (OUI ou NON)
# Si > 50%, on considère que c'est un achat probable
test$prediction <- ifelse(test$prob >= 0.5, "Mobilhome_1", "Mobilhome_0")

# 3. Mise en forme obligatoire pour la fonction confusionMatrix

test$prediction <- factor(test$prediction, levels = levels(test$Mobilhome))

# 4. Affichage de la Matrice de Confusion et du Taux de Réussite
matrice <- confusionMatrix(data = test$prediction, reference = test$Mobilhome)
print(matrice)
```

ESER Enes
MARFOUK Omar
VCOD

Ciblage des Prospects :

Code R :

#50 clients

1. On isole les "PROSPECTS"

Ce sont les clients dans la base qui n'ont PAS l'assurance (Mobilhome_0)

C'est sur eux qu'on veut faire du business.

```
prospects <- donnees[donnees$Mobilhome == "Mobilhome_0", ]
```

```
print(paste("Nombre de prospects à analyser :", nrow(prospects)))
```

2. On calcule le SCORE

On applique le modèle mathématique sur ces gens-là

type="response" nous donne un % de chance entre 0 et 1

```
prospects$SCORE <- predict(modele, newdata = prospects, type = "response")
```

3. On trie la liste du plus chaud au plus froid

order(..., decreasing = TRUE) met les plus forts scores en haut de la liste

```
trie <- prospects[order(prospects$SCORE, decreasing = TRUE), ]
```

4. On sélectionne les 50 meilleurs (TOP 50)

```
top_50 <- head(trie, 50)
```

5. Affichage propre pour le rapport

On sélectionne les colonnes intéressantes pour voir POURQUOI ils sont choisis

```
colonne<- c("avgincom", "Car", "avgsiz", "SCORE")
```

```
print(top_50[, colonne])
```

```
write.csv(top_50, file = "Top50_Clients_Prioritaires.csv", row.names = FALSE)
```